Resolução da lista 4

Curso de inferência causal

Camila Brito

```r
# carregando os pacotes
library(microdatasus)
library(dplyr)
library(ggplot2)

# lendo os dados
data <- fetch_datasus(
    year_start = 2023, month_start = 1, year_end = 2023, month_end = 12,
    information_system = "SINASC", uf = "GO"
)
```

Parte I - Preparação dos dados e correlações

1. Preparação dos dados

Seleção das colunas necessárias, de acordo com a referência.

```r
s_data <- data |>
  select(PESO, IDADEMAE, ESCMAE, CONSULTAS, GESTACAO) |>
  mutate(
    peso = as.numeric(PESO),
    idade_mae = as.numeric(IDADEMAE),
    escolaridade_mae_numerico = as.numeric(ESCMAE),
    escolaridade_mae = factor(
      ESCMAE,
      levels = c('1', '2', '3', '4', '5', '9'),
      labels = c('Nenhuma', '1-3', '4-7', '8-11','12+', 'ignorado'),
      # ordered = TRUE
    ),
```

```r
    consultas = as.numeric(CONSULTAS),
    consultas_factor = factor(
      CONSULTAS,
      levels = c('1', '2', '3', '4', '9'),
      labels = c('Nenhuma', '1-3', '4-6', '7+', 'ignorado'),
      ordered = TRUE
    ),
    semanas_gestacao = factor(
        GESTACAO,
        levels = c('1', '2', '3', '4', '5', '6', '9'),
        labels = c('menos 22', '22-27', '28-31', '32-36', '37-41', '42+', 'ignorado')
    )
  ) |>
  select(peso, idade_mae, escolaridade_mae_numerico, escolaridade_mae, consultas, consultas_
  na.omit() |>
  # removendo as colunas marcadas como 'ignorado'
  filter(consultas != 9 & escolaridade_mae != 'ignorado' & semanas_gestacao != 'ignorado')

summary(s_data)
```

```
      peso        idade_mae     escolaridade_mae_numerico escolaridade_mae
 Min.   : 135   Min.   :11.00   Min.   :1.000             Nenhuma :   59
 1st Qu.:2845   1st Qu.:22.00   1st Qu.:4.000             1-3     :  452
 Median :3150   Median :27.00   Median :4.000             4-7     : 6340
 Mean   :3110   Mean   :27.45   Mean   :4.204             8-11    :58530
 3rd Qu.:3445   3rd Qu.:32.00   3rd Qu.:5.000             12+     :26075
 Max.   :6550   Max.   :58.00   Max.   :5.000             ignorado:    0

   consultas     consultas_factor semanas_gestacao
 Min.   :1.000   Nenhuma :  938   menos 22:   49
 1st Qu.:4.000   1-3     : 4494   22-27   :  475
 Median :4.000   4-6     :16717   28-31   :  916
 Mean   :3.688   7+      :69307   32-36   : 9018
 3rd Qu.:4.000   ignorado:    0   37-41   :79575
 Max.   :4.000                    42+     : 1423
                                  ignorado:    0
```

2. Identificando as variáveis no framework causal

Definindo o tratamento D_i como o número adequado de consultas pré-natal (mais de 7 consultas).

```r
# Criação da variável de tratamento
t_data <- s_data |>
    mutate(
        pre_natal_adequado = ifelse(consultas == 4, 1, 0)
    )
```

a. A proporção de bebês cujas mães realizaram o pré-natal adequado é dado por

```r
t_data |> group_by(pre_natal_adequado) |> summarise(n = n(), proporcao = 100*(n/nrow(t_data)
```

```
# A tibble: 2 x 3
  pre_natal_adequado     n proporcao
               <dbl> <int>     <dbl>
1                  0 22149      24.2
2                  1 69307      75.8
```

b. $Y_i(1)$ é o peso do bebê i quando a mãe realizou o pré-natal adequado ($D_i = 1$), enquanto $Y_i(0)$ é o peso do mesmo bebê i quando a mãe não realizou o pré-natal adequado ($D_i = 0$).

c. Não é possível observar os dois pois o contrafactual é sempre uma situação hipotética caso o indivíduo não tenha recebido o tratamento. Isso implica que não conseguimos calcular diretamente o efeito do tratamento sobre os indivíduos.

3. Correlação e visualização

a. A correlação entre o peso ao nascer e a realização adequada do pré-natal é dada por

```r
corr = cov(t_data$peso, t_data$pre_natal_adequado)/(sd(t_data$peso)*sd(t_data$pre_natal_adequ
corr
```

```
[1] 0.1328936
```

O valor positivo porém próximo de zero sugere que há pouca relação linear diretamente proporcional.

b. Essa correlação não pode ser interpretada como causal, pois podem existir variáveis confundidoras que influenciam tanto o tratamento quanto o resultado, gerando viés. Algumas dessas variáveis podem ser idade da mãe (mães mais velhas podem ter maior estabilidade financeira e maturidade biológica), renda/escolaridade/local de moradia da mãe (podem afetar o acesso a serviços de saúde e alimentação de qualidade), etc.

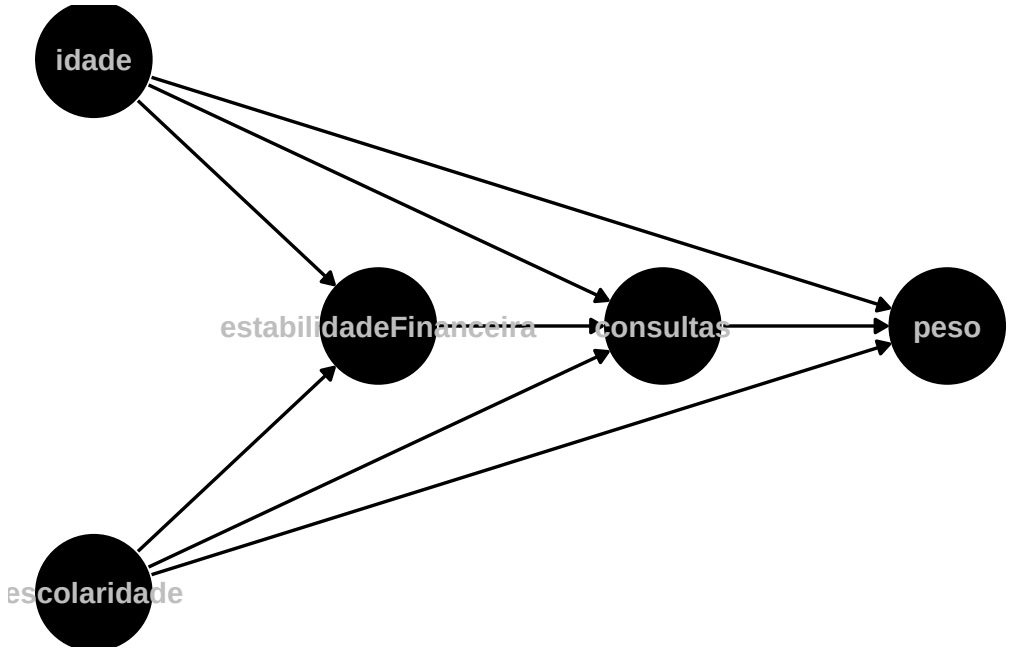

c.

```
t_data |> ggplot() +
    aes(y = escolaridade_mae, x = peso, fill = escolaridade_mae) +
    geom_boxplot(alpha=0.3) +
    theme(legend.position='none')
```

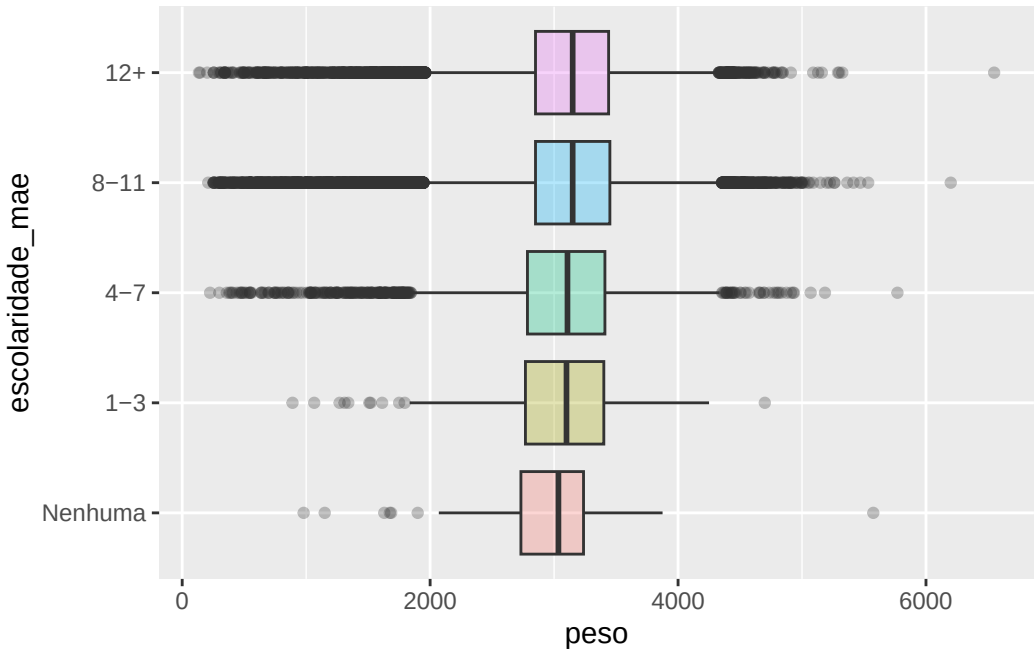

As medianas do peso ao nascer não variam muito em relação ao nível de escolaridade da mãe, sendo um pouco menores quando a mãe não tem nenhuma escolaridade.

Parte II - Comparação observacional e viés de seleção

4. SDO

a.

```
d0 <- t_data |> filter(pre_natal_adequado == 0)
d1 <- t_data |> filter(pre_natal_adequado == 1)

sdo <- mean(d1$peso) - mean(d0$peso)
sdo
```

```
[1] 167.4577
```

O SDO representa a diferença simples da média do resultado dos tratados (média dos pesos para mães que realizaram o pré-natal adequado) e da média do resultado dos não tratados (média dos pesos para mães que não realizaram o pré-natal adequado). Esse valor **não** corresponde à ATE, ele é apenas a comparação dos resultados obtidos entre tratados e controle e não a comparação dos resultados potenciais.

b. O SDO pode ser uma estimativa enviesada do efeito do pré-natal sobre o peso ao nascer pois os valores de $Y(0)$ para os tratados e o controle podem ser diferentes, fazendo com que os grupos não sejam comparáveis antes do tratamento.

c.

$$SDO = E[Y(1)|D=1] - E[Y(0)|D=0] \tag{1}$$
$$SDO = \underbrace{E[Y(1)|D=1] - E[Y(0)|D=1]}_{\text{ATT}} + \underbrace{E[Y(0)|D=1] - E[Y(0)|D=0]}_{\text{Viés de seleção}} \tag{2}$$

O sinal esperado do viés nesse contexto é positivo, ou seja, o $Y(0)$ das mães que realizaram pré-natal adequado ($D=1$) tende a ser maior que o das mães que não realizaram o pré-natal adequado. Isso se dá pelas variáveis confundidoras discutidas anteriormente em que uma mãe que realizou o pré-natal corretamente já tenderia a ter bebês com maior peso devido à possível maior renda, maior acesso a serviços de saúde, maior maturidade etc.

5. Investigando o viés de seleção

a.

- Comparação da idade das mães nos grupos

```r
t.test(idade_mae ~ pre_natal_adequado, data = t_data)
```

```
    Welch Two Sample t-test

data:  idade_mae by pre_natal_adequado
t = -43.44, df = 37029, p-value < 2.2e-16
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to
95 percent confidence interval:
 -2.266562 -2.070857
sample estimates:
mean in group 0 mean in group 1
       25.80708        27.97579
```

- Comparação da escolaridade das mães nos grupos:

```r
t.test(escolaridade_mae_numerico ~ pre_natal_adequado, data = t_data)
```

```
    Welch Two Sample t-test

data:  escolaridade_mae_numerico by pre_natal_adequado
t = -58.188, df = 38320, p-value < 2.2e-16
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to
95 percent confidence interval:
 -0.2612809 -0.2442522
sample estimates:
mean in group 0 mean in group 1
       4.012416        4.265182
```

```r
t_data |>
  group_by(pre_natal_adequado) |>
  summarise(
    media_idade = mean(idade_mae),
    media_escolaridade = mean(escolaridade_mae_numerico)
  )
```

```
# A tibble: 2 x 3
  pre_natal_adequado media_idade media_escolaridade
               <dbl>       <dbl>              <dbl>
1                  0        25.8               4.01
2                  1        28.0               4.27
```

Como p $<$ 0.05 para as médias de escolaridade e idade nos dois grupos, temos que o grupo de controle e o de tratamento não são iguais para essas variáveis e não são comparáveis.

```r
aux_data <- t_data |>
  mutate(
    pre_natal_adequado = ifelse(pre_natal_adequado == 1, 'D=1', 'D=0')
  )

aux_data |> ggplot() +
  aes(x = idade_mae, fill = pre_natal_adequado) +
  geom_density(alpha = 0.3)
```

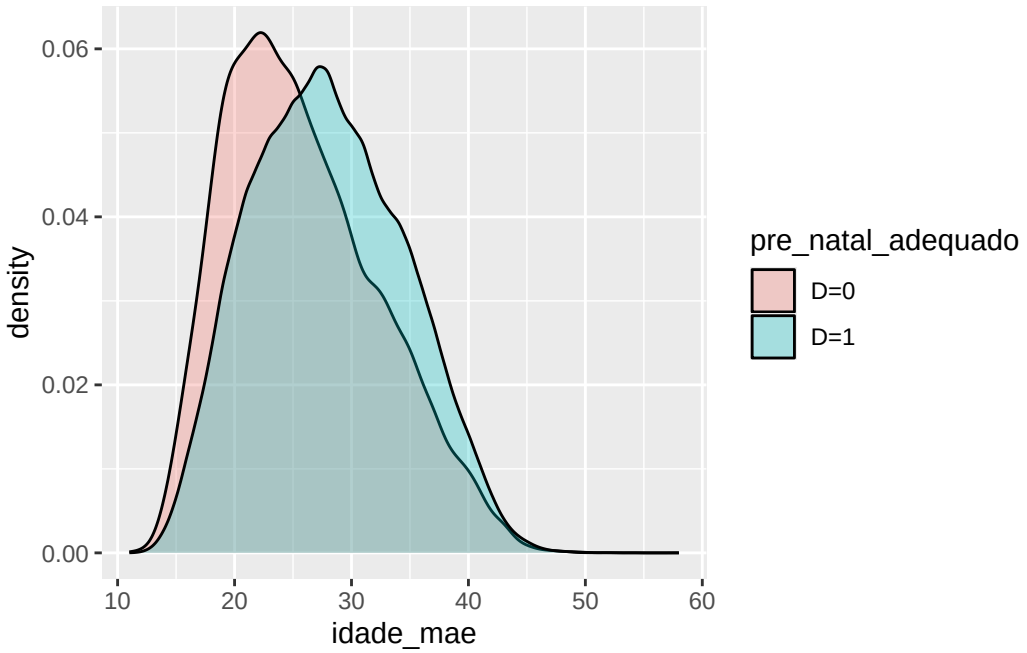

b. Com base nos resultados, o viés de seleção presente é do tipo Y^0: as mães tratadas, levemente mais velhas, já teriam bebês com pesos diferentes das mães não tratadas, mesmo sem realizar o número adequado de consultas. Isso pode se dar por já poderem ter uma maior estabilidade financeira, maior acesso a serviços de saúde, maior maturidade biológica, etc.

Além disso, também podemos enxergar um viés em Y^1. Mulheres mais velhas podem responder melhor ao tratamento por terem mais maturidade e aderirem melhor às orientações médicas e terem mais acesso aos suplementos vitamínicos prescritos.

c.

```
aux_data |> ggplot() +
  aes(x = peso, fill = pre_natal_adequado) +
  geom_density(alpha = 0.3)
```

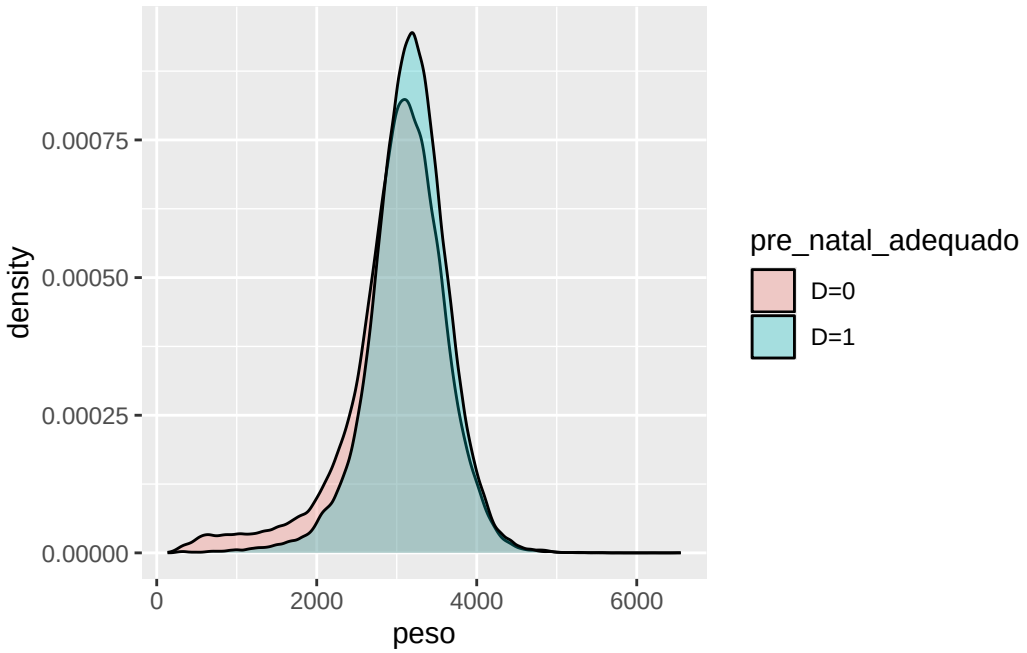

Como é possível analisar no gráfico, os bebês de mães tratadas (pré-natal adequado) tem o peso levemente maior que o de mães não tratadas.

6. Regressão com controles como alternativa

a.

- Modelo sem covariadas

```
modelo_simples <- lm(peso ~ pre_natal_adequado, data = t_data)
summary(modelo_simples)
```

```
Call:
lm(formula = peso ~ pre_natal_adequado, data = t_data)

Residuals:
   Min     1Q Median     3Q    Max 
 -3016   -271     34    329   3566 

Coefficients:
                   Estimate Std. Error t value Pr(>|t|)
```

```
(Intercept)        2983.536      3.595  829.89   <2e-16 ***
pre_natal_adequado  167.458      4.130   40.55   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 535 on 91454 degrees of freedom
Multiple R-squared:  0.01766,   Adjusted R-squared:  0.01765
F-statistic:  1644 on 1 and 91454 DF,  p-value: < 2.2e-16
```

- Modelo com covariadas

```r
modelo_covariada <- lm(peso ~ pre_natal_adequado + idade_mae + escolaridade_mae, data = t_dat
summary(modelo_covariada)
```

```
Call:
lm(formula = peso ~ pre_natal_adequado + idade_mae + escolaridade_mae,
    data = t_data)

Residuals:
    Min      1Q  Median      3Q     Max
-2993.6  -271.1    35.5   330.0  3590.7

Coefficients:
                      Estimate Std. Error t value Pr(>|t|)
(Intercept)          2803.6909    70.2829  39.892   <2e-16 ***
pre_natal_adequado    169.3126     4.2247  40.077   <2e-16 ***
idade_mae               0.6873     0.2893   2.376   0.0175 *
escolaridade_mae1-3   138.9010    74.0385   1.876   0.0606 .
escolaridade_mae4-7   137.6745    69.9728   1.968   0.0491 *
escolaridade_mae8-11  171.4004    69.6974   2.459   0.0139 *
escolaridade_mae12+   139.0677    69.7234   1.995   0.0461 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 534.8 on 91449 degrees of freedom
Multiple R-squared:  0.01848,   Adjusted R-squared:  0.01842
F-statistic:   287 on 6 and 91449 DF,  p-value: < 2.2e-16
```

O coeficiente de D (pré-natal adequado) muda muito pouco após incluir os controles. Isso significa que as variáveis controladas adicionam pouco viés de seleção ao efeito do tratamento.

b. Não necessariamente o coeficiente de D no modelo com controles pode ser interpretado como efeito causal do pré-natal adequado sobre o peso a nascer. Para que pudessemos fazer essa afirmação, seria necessário que controlássemos para todas as variáveis confundidoras do tratamento e do efeito.

Vamos controlar agora por uma variável confundidora mais óbvia: número de semanas de gestação. Essa variável influencia tanto o peso ao nascer quanto o número de consultas pré-natal.

```r
modelo_covariada2 <- lm(peso ~ pre_natal_adequado + idade_mae + escolaridade_mae + semanas_ge
summary(modelo_covariada2)
```

```
Call:
lm(formula = peso ~ pre_natal_adequado + idade_mae + escolaridade_mae +
    semanas_gestacao, data = t_data)

Residuals:
    Min      1Q  Median      3Q     Max
-2977.0  -287.6    -8.2   277.4  3784.6

Coefficients:
                       Estimate Std. Error t value Pr(>|t|)
(Intercept)            674.5631    88.0774   7.659  1.9e-14 ***
pre_natal_adequado      52.6429     3.6382  14.469  < 2e-16 ***
idade_mae                2.4197     0.2457   9.847  < 2e-16 ***
escolaridade_mae1-3     75.4305    62.8285   1.201   0.2299
escolaridade_mae4-7     83.0828    59.3775   1.399   0.1617
escolaridade_mae8-11   115.1677    59.1437   1.947   0.0515 .
escolaridade_mae12+     90.5946    59.1658   1.531   0.1257
semanas_gestacao22-27  140.3401    68.0971   2.061   0.0393 *
semanas_gestacao28-31  748.5022    66.5538  11.247  < 2e-16 ***
semanas_gestacao32-36 1688.0666    65.0403  25.954  < 2e-16 ***
semanas_gestacao37-41 2312.5889    64.9009  35.633  < 2e-16 ***
semanas_gestacao42+   2381.4373    65.9876  36.089  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 453.8 on 91444 degrees of freedom
Multiple R-squared:  0.2933,    Adjusted R-squared:  0.2932
F-statistic:  3450 on 11 and 91444 DF,  p-value: < 2.2e-16
```

Nesse novo modelo, podemos observar que o coeficiente do tratamento diminui bastante, mostrando que o número de semanas gestacionais gerava bastante viés.

c. Em um RTC, estimaríamos de fato o efeito causal do tratatamento sobre o resultado, pois eliminaríamos todos os vieses causados por possíveis variáveis confundidoras ao aleatorizar os grupos e torná-los comparáveis antes do tratamento. No nosso modelo com controle de covariadas, estamos estimando a associação entre tratamento e efeito sem levar em consideração o efeito das confudidoras que controlamos. Os dois seriam iguais caso fosse possível controlar por todas as confundidoras.

Parte III - Simulando a Aleatorização

7. Atribuição aleatória de tratamento

```
t_data <- t_data |>
  mutate(
    tratamento_aleatorio = sample(c(0, 1), size = n(), replace = TRUE)
  )

d0_a <- t_data |> filter(tratamento_aleatorio == 0)
d1_a <- t_data |> filter(tratamento_aleatorio == 1)

sdo_a <- mean(d1_a$peso) - mean(d0_a$peso)
sdo_a
```

```
[1] 3.337078
```

a . O SDO com tratamento aleatório difere muito do SDO observado, tendendo a zero. Essa diferença nos diz que, como o tratamento aleatorizado não tem nenhum efeito sobre o resultado (peso do bebê), seu ATE é zero, tal qual o SDO, mostrando que o viés de seleção não existe mais.

b.

- Comparação da idade das mães nos grupos

```
t.test(idade_mae ~ tratamento_aleatorio, data = t_data)
```

```
    Welch Two Sample t-test

data:  idade_mae by tratamento_aleatorio
t = 0.39913, df = 91449, p-value = 0.6898
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to
95 percent confidence interval:
 -0.06710431  0.10142288
sample estimates:
mean in group 0 mean in group 1
       27.45917        27.44201
```

- Comparação da escolaridade das mães nos grupos

```r
t.test(escolaridade_mae_numerico ~ tratamento_aleatorio, data = t_data)
```

```
    Welch Two Sample t-test

data:  escolaridade_mae_numerico by tratamento_aleatorio
t = 0.7223, df = 91446, p-value = 0.4701
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to
95 percent confidence interval:
 -0.004761737  0.010319478
sample estimates:
mean in group 0 mean in group 1
       4.205360        4.202582
```

```r
t_data |>
  group_by(tratamento_aleatorio) |>
  summarise(
    media_idade = mean(idade_mae),
    media_escolaridade = mean(escolaridade_mae_numerico)
  )
```

```
# A tibble: 2 x 3
  tratamento_aleatorio media_idade media_escolaridade
                 <dbl>       <dbl>              <dbl>
1                    0        27.5               4.21
2                    1        27.4               4.20
```

Os grupos estão bastante equilibrados agora, sendo estatisticamente iguais (p » 0.05 para o teste que compara as médias nos dois grupos), pois as amostras foram feitas aleatoriamente.

c. O SDO aleatorizado é uma estimativa causal válida, mostranto o efeito do tratamento aleatório sobre o resultado (que é 0). Lembrando que, já que o tratamento foi atribuído aleatoriamente, ele não tem de fato nenhuma relação com o peso observado dos bebês.

8. Distribuição do estimador sob aleatorização

```
sdos = c()

for (i in 1:1000){

  data_aux <- t_data |>
  mutate(
    tratamento_aleatorio_s = sample(c(0, 1), size = n(), replace = TRUE)
  )

  d0_aux <- data_aux |> filter(tratamento_aleatorio_s == 0)
  d1_aux <- data_aux |> filter(tratamento_aleatorio_s == 1)

  sdo_aux <- mean(d1_aux$peso) - mean(d0_aux$peso)
  sdos <- c(sdos, sdo_aux)
}

summary(sdos)
```

```
     Min.   1st Qu.    Median      Mean   3rd Qu.      Max.
-12.23678  -2.57894   0.01868   0.02197   2.56761  10.94883
```

```
df_sdos <- data.frame(sdos)
df_sdos |> ggplot() + aes(x=sdos) + geom_density()
```

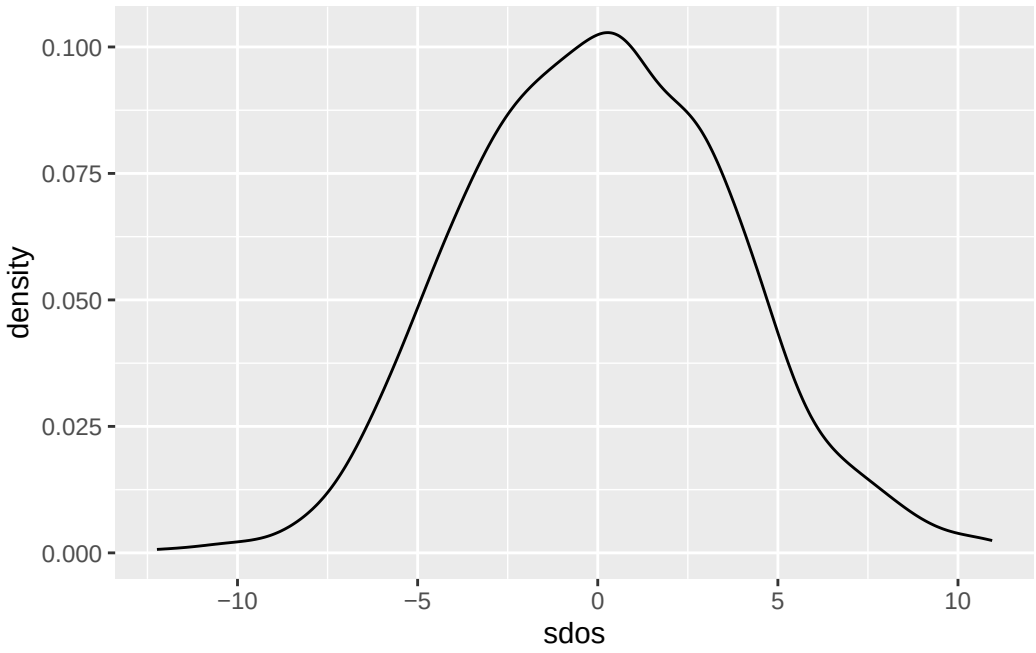

a. A distribuição do SDO aleatorizado se concentra em torno do zero. Isso é coerente com a teoria, pois o tratamento aleatório não tem correlação e nem efeito causal sobre o peso do bebê ao nascer. Assim, o SDO se aproxima do ATE do tratamento aleatório, já que elimina o viés.

b.

```
desvio <- sd(sdos, na.rm = TRUE)
desvio
```

```
[1] 3.650307
```

O desvio é equivalente ao erro padrão do coeficiente estimado na regressão.

c. O SDO observado é muito maior que o SDO do tratamento aleatório, onde não há viés de seleção.

9. Inferência causal: regressão no contexto de um RTC simulado

a.

```r
modelo_simples_a <- lm(peso ~ tratamento_aleatorio, data = t_data)
summary(modelo_simples_a)
```

```
Call:
lm(formula = peso ~ tratamento_aleatorio, data = t_data)

Residuals:
    Min      1Q  Median      3Q     Max 
-2973.8  -267.1    37.9   332.9  3441.2 

Coefficients:
                     Estimate Std. Error  t value Pr(>|t|)    
(Intercept)          3108.765      2.528 1229.645   <2e-16 ***
tratamento_aleatorio    3.337      3.570    0.935     0.35    
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 539.8 on 91454 degrees of freedom
Multiple R-squared:  9.553e-06, Adjusted R-squared:  -1.381e-06 
F-statistic: 0.8737 on 1 and 91454 DF,  p-value: 0.3499
```

O coeficiente de D não é estatisticamente significativo ($p > 0.05$). Isso indica que nessa simulação, não há efeito causal e nem correlação entre o peso ao nascer e o tratamento aleatório.

b.

```r
modelo_covariada_a <- lm(peso ~ tratamento_aleatorio + idade_mae + escolaridade_mae, data = t
summary(modelo_covariada_a)
```

```
Call:
lm(formula = peso ~ tratamento_aleatorio + idade_mae + escolaridade_mae, 
    data = t_data)

Residuals:
    Min      1Q  Median      3Q     Max 
-2962.7  -267.3    39.4   332.0  3452.6 

Coefficients:
```

```
                      Estimate Std. Error t value Pr(>|t|)
(Intercept)          2860.9912    70.9112  40.346  < 2e-16 ***
tratamento_aleatorio    3.3716     3.5681   0.945  0.34471
idade_mae               1.8553     0.2903   6.390 1.66e-10 ***
escolaridade_mae1-3   142.8426    74.6866   1.913  0.05581 .
escolaridade_mae4-7   146.9193    70.5844   2.081  0.03739 *
escolaridade_mae8-11  205.0563    70.3019   2.917  0.00354 **
escolaridade_mae12+   191.8719    70.3208   2.729  0.00636 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 539.5 on 91449 degrees of freedom
Multiple R-squared:  0.001251,  Adjusted R-squared:  0.001185
F-statistic: 19.09 on 6 and 91449 DF,  p-value: < 2.2e-16
```

O erro padrão ddo modelo com as covariadas diminui um pouco. Mesmo o RCT eliminando o viés e a necessidade de controlar variáveis, adicionar covariadas que explicam o resultado podem diminuir a variância da estimativa e melhorar sua precisão.

c. O RCT satifaz a hipótese da independência, que torna os grupos de controle e tratamento comparáveis, o que não acontece no dado observado, em que há viés de seleção.