

Resolução da lista 6

Curso de inferência causal

Camila Brito

```
# carregando os pacotes
library(microdatasus)
library(dplyr)
library(ggplot2)
library(AER)

# lendo os dados
data <- fetch_datasus(
  year_start = 2023, month_start = 1, year_end = 2023, month_end = 12,
  information_system = "SINASC", uf = "GO"
)
```

Seção I - Preparação dos dados e construção do instrumento

1. Carregamento e construção do instrumento municipal

- a. Seleção das colunas necessárias, de acordo com a [referência](#) e criação da variável de tratamento `pre_natal_adequado`.

```
s_data <- data |>
  select(PESO, IDADEMAE, ESCMAE, CONSULTAS, GESTACAO, CODMUNRES) |>
  mutate(
    peso = as.numeric(PESO),
    idade_mae = as.numeric(IDADEMAE),
    escolaridade_mae_numerico = as.numeric(ESCMAE),
    escolaridade_mae = factor(
      ESCMAE,
      levels = c('1', '2', '3', '4', '5', '9'),
      labels = c('Nenhuma', '1-3', '4-7', '8-11', '12+', 'ignorado'),
    )
  )
```

```

# ordered = TRUE
),
consultas = as.numeric(CONSULTAS),
consultas_factor = factor(
CONSULTAS,
levels = c('1', '2', '3', '4', '9'),
labels = c('Nenhuma', '1-3', '4-6', '7+', 'ignorado'),
ordered = TRUE
),
semanas_gestacao = factor(
GESTACAO,
levels = c('1', '2', '3', '4', '5', '6', '9'),
labels = c('menos 22', '22-27', '28-31', '32-36', '37-41', '42+', 'ignorado')
),
codigo_municipio = CODMUNRES
) |>
select(peso, idade_mae, escolaridade_mae_numerico, escolaridade_mae,
consultas, consultas_factor, semanas_gestacao, codigo_municipio) |>
na.omit() |>
# removendo as colunas marcadas como 'ignorado'
filter(consultas != 9 & escolaridade_mae != 'ignorado') |>
# criando a variável de tratamento
mutate(
pre_natal_adequado = ifelse(consultas == 4, 1, 0)
)

```

b.

```

t_data <- s_data |>
group_by(codigo_municipio) |>
mutate(
Z_mun = mean(pre_natal_adequado, na.rm = TRUE)
)

# quantidade de municípios distintos
length(unique(t_data$codigo_municipio))

```

[1] 247

```

# distribuição do instrumento
summary(t_data$Z_mun)

```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.3400	0.7149	0.7627	0.7578	0.7826	1.0000


```
# desvio padrão do instrumento
sd(t_data$Z_mun)
```

```
[1] 0.06921152
```

c.

```
histograma <- t_data |>
  ggplot() +
  aes(x = Z_mun) +
  geom_histogram(binwidth = 0.05)

histograma
```



Existem municípios com cobertura muito baixa, configurando um outlier em torno de 0.3. Também existem municípios com cobertura muita alta, em 100%. A maioria dos valores, no entanto, está por volta de 0.75. Essa heterogeneidade pode se dar por diversos motivos, como se o município é urbano ou rural, municípios o alcance dos serviços de saúde, a quantidade de mulheres grávidas em cada local etc.

2. Verificação do primeiro estágio

a.

```
primeiro_estagio <- lm(  
  pre_natal_adequado ~ Z_mun + escolaridade_mae + idade_mae, data = t_data)  
summary(primeiro_estagio)
```

Call:

```
lm(formula = pre_natal_adequado ~ Z_mun + escolaridade_mae +  
    idade_mae, data = t_data)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-1.16436	-0.02661	0.17633	0.27986	0.72471

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.3766544	0.0563979	-6.679	2.43e-11 ***
Z_mun	0.9482395	0.0197848	47.928	< 2e-16 ***
escolaridade_mae1-3	0.0320235	0.0572381	0.559	0.575837
escolaridade_mae4-7	0.0660025	0.0540950	1.220	0.222422
escolaridade_mae8-11	0.2029766	0.0538780	3.767	0.000165 ***
escolaridade_mae12+	0.3094454	0.0538922	5.742	9.39e-09 ***
idade_mae	0.0070315	0.0002225	31.600	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4135 on 91449 degrees of freedom

Multiple R-squared: 0.06857, Adjusted R-squared: 0.06851


F-statistic: 1122 on 6 and 91449 DF, p-value: < 2.2e-16

No primeiro estágio, o coeficiente do instrumento nos diz o impacto do instrumento no tratamento. Nesse caso, o coeficiente $\beta = 0.95$, estatisticamente significativo ($p \ll 0.05$), nos diz que a relação entre instrumento e tratamento é positiva e que cada unidade de aumento do instrumento aumenta em 0.95 o tratamento (ou que o aumento de 1% no instrumento, aumenta o tratamento em 0.0095 o tratamento, que é dummy). A estatística F é de 1122, passando tanto no critério histórico de $F > 10$ quanto no critério de Lee et al. Isso mostra que nosso instrumento é forte/relevante.

- b. É esperado ver uma linha perfeitamente linear, visto que a variável de instrumento Z_mun é justamente a média do tratamento (mães com pré natal adequado) por município.

```
data_munic <- t_data |>
  group_by(codigo_municipio) |>
  mutate(
    media_tratamento = mean(pre_natal_adequado)
  )

dispersao <- data_munic |>
  ggplot() + aes(x = Z_mun, y = media_tratamento) + geom_point()
dispersao
```



- c. Um primeiro estágio fraco implicaria um instrumento fraco. Usando a fórmula com $F = 2$, o viés tenderia a $\frac{\sigma_{v\varepsilon}}{\sigma_{\eta}^2} * \frac{1}{3}$, que é um terço do viés do MQO, herdado pelo instrumento.

Seção II - Estimação de IV e Comparação com MQO

3. Forma reduzida e razão de Wald

- a.

```
forma_reduzida <- lm(
  peso ~ Z_mun + escolaridade_mae + idade_mae, data = t_data)
summary(forma_reduzida)
```

Call:

```
lm(formula = peso ~ Z_mun + escolaridade_mae + idade_mae, data = t_data)
```

Residuals:

Min	1Q	Median	3Q	Max
-2964.1	-267.4	39.3	332.1	3451.4

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2852.4748	73.5899	38.762	< 2e-16 ***
Z_mun	13.6523	25.8159	0.529	0.59692
escolaridade_mae1-3	142.6103	74.6863	1.909	0.05621 .
escolaridade_mae4-7	146.8625	70.5850	2.081	0.03747 *
escolaridade_mae8-11	204.8889	70.3019	2.914	0.00356 **
escolaridade_mae12+	191.5981	70.3205	2.725	0.00644 **
idade_mae	1.8572	0.2903	6.396	1.6e-10 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 539.5 on 91449 degrees of freedom

Multiple R-squared: 0.001244, Adjusted R-squared: 0.001178

F-statistic: 18.98 on 6 and 91449 DF, p-value: < 2.2e-16

O coeficiente do instrumento na forma reduzida nos diz o impacto do instrumento na variável resposta. Nesse caso, o coeficiente $\beta = 13.65$, que não é estatisticamente significativo ($p > 0.05$), nos diz que a relação entre instrumento e resultado é positiva e que cada unidade de aumento do instrumento aumenta em 13.65g o peso ao nascer (resultado). Ou seja, o impacto do instrumento no resultado não é relevante.

b.

A razão de Wald é dada por

```
wald = forma_reduzida$coefficients["Z_mun"][[1]]/primeiro_estagio$coefficients["Z_mun"][[1]]
wald
```

```
[1] 14.39757
```

Já o coeficiente de tratamento no MQO é dado por

```
regressao_simples = lm(
  peso ~ pre_natal_adequado + escolaridade_mae + idade_mae, data = t_data)
regressao_simples$coefficients["pre_natal_adequado"][[1]]
```

```
[1] 169.3126
```

A razão de Wald é muito menor, próxima de zero, mostrando que o impacto de consultas pré-natal no peso é muito baixa e que o valor estimado por MQO tem viés de seleção.

c.

```
d0 <- t_data |> filter(pre_natal_adequado == 0)
d1 <- t_data |> filter(pre_natal_adequado == 1)

sdo <- mean(d1$peso) - mean(d0$peso)
sdo
```

```
[1] 167.4577
```

A razão de Wald é bem menor que o SDO observacional. Supondo que nosso instrumento é válido e o seu efeito é homogêneo, a razão de Wald seria um bom estimador de ATT. Considerando que $SDO = ATT + vis$, como Wald é bem menor que SDO, o sinal do viés é **positivo**. Isso mostra que mães que fazem mais consultas pré-natal tendem a ter bebês mais pesados independente das consultas.

4. MQO vs MQ2E

a.

O MQO é dado por

```
regressao_simples = lm(
  peso ~ pre_natal_adequado + escolaridade_mae + idade_mae, data = t_data)
summary(regressao_simples)
```

Call:

```
lm(formula = peso ~ pre_natal_adequado + escolaridade_mae + idade_mae,  
    data = t_data)
```

Residuals:

Min	1Q	Median	3Q	Max
-2993.6	-271.1	35.5	330.0	3590.7

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2803.6909	70.2829	39.892	<2e-16 ***
pre_natal_adequado	169.3126	4.2247	40.077	<2e-16 ***
escolaridade_mae1-3	138.9010	74.0385	1.876	0.0606 .
escolaridade_mae4-7	137.6745	69.9728	1.968	0.0491 *
escolaridade_mae8-11	171.4004	69.6974	2.459	0.0139 *
escolaridade_mae12+	139.0677	69.7234	1.995	0.0461 *
idade_mae	0.6873	0.2893	2.376	0.0175 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 534.8 on 91449 degrees of freedom

Multiple R-squared: 0.01848, Adjusted R-squared: 0.01842

F-statistic: 287 on 6 and 91449 DF, p-value: < 2.2e-16

O MQ2E é dado por

```
regressao_iv = ivreg(peso ~ pre_natal_adequado + escolaridade_mae + idade_mae |  
    Z_mun + escolaridade_mae + idade_mae, data = t_data)  
summary(regressao_iv)
```

Call:

```
ivreg(formula = peso ~ pre_natal_adequado + escolaridade_mae +  
    idade_mae | Z_mun + escolaridade_mae + idade_mae, data = t_data)
```

Residuals:

Min	1Q	Median	3Q	Max
-2966.6	-267.2	39.1	331.1	3462.8

Coefficients:

Estimate	Std. Error	t value	Pr(> t)
----------	------------	---------	----------


```

(Intercept)          2857.8977    71.4184  40.016 < 2e-16 ***
pre_natal_adequado    14.3976    27.1868   0.530  0.59640
escolaridade_mae1-3   142.1492    74.5830   1.906  0.05666 .
escolaridade_mae4-7   145.9122    70.4998   2.070  0.03848 *
escolaridade_mae8-11  201.9665    70.4076   2.869  0.00412 **
escolaridade_mae12+   187.1429    70.7267   2.646  0.00815 **
idade_mae             1.7559     0.3453   5.085  3.68e-07 ***

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 538.8 on 91449 degrees of freedom

Multiple R-Squared: 0.004048, Adjusted R-squared: 0.003983

Wald test: 19.04 on 6 and 91449 DF, p-value: < 2.2e-16

b.

```
summary(regressao_iv, diagnostics = TRUE)
```

Call:

```
ivreg(formula = peso ~ pre_natal_adequado + escolaridade_mae +
      idade_mae | Z_mun + escolaridade_mae + idade_mae, data = t_data)
```

Residuals:

Min	1Q	Median	3Q	Max
-2966.6	-267.2	39.1	331.1	3462.8

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2857.8977	71.4184	40.016	< 2e-16 ***
pre_natal_adequado	14.3976	27.1868	0.530	0.59640
escolaridade_mae1-3	142.1492	74.5830	1.906	0.05666 .
escolaridade_mae4-7	145.9122	70.4998	2.070	0.03848 *
escolaridade_mae8-11	201.9665	70.4076	2.869	0.00412 **
escolaridade_mae12+	187.1429	70.7267	2.646	0.00815 **
idade_mae	1.7559	0.3453	5.085	3.68e-07 ***

Diagnostic tests:

	df1	df2	statistic	p-value
Weak instruments	1	91449	2297.07	< 2e-16 ***
Wu-Hausman	1	91448	33.79	6.17e-09 ***
Sargan	0	NA	NA	NA

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 538.8 on 91449 degrees of freedom

Multiple R-Squared: 0.004048, Adjusted R-squared: 0.003983

Wald test: 19.04 on 6 and 91449 DF, p-value: < 2.2e-16

- Weak instruments mede a relevância do instrumento com a estatística F (a hipótese nula é de que o instrumento é fraco): no nosso caso, $F = 2297$ e $p \ll 0.05$, mostrando que temos um instrumento forte
- O teste de Wu-Hausman mede a endogeneidade do tratamento e a consequente necessidade de um instrumento (a hipótese nula é de que o tratamento é exógeno): no nosso caso, como $p \ll 0.05$, rejeitamos a exogeneidade e entendemos que o tratamento é endógeno.

c. O coeficiente D no modelo IV não é necessariamente casualmente interpretável. As hipóteses que precisam ser válidas são

- relevância, o instrumento impacta o tratamento
- exclusão, a única forma que o instrumento (proporção média de mães com pré natal adequado por município) impacta no resultado é pelo tratamento
- independência, o instrumento é aleatório em relação ao resultado
- monotonicidade, o instrumento afeta o tratamento na mesma direção para todos

As principais ameaças à validade causal nesse contexto são as hipóteses de exclusão e de independência. - ameaça à exclusão: o instrumento (cobertura municipal) pode influenciar o resultado de outras formas que não através do tratamento. Mulheres de municípios com maior cobertura podem também ter mais acesso à educação, alimentação de melhor qualidade etc. - ameaça à independência: o instrumento não é aleatório em relação ao resultado, ou seja, não é exógeno, tornando os grupos não comparáveis

5. LATE e interpretação dos resultados

a. A proporção de compliers pode ser aproximado pelo coeficiente do primeiro estágio:

$$p(\text{compliers}) = \frac{ITT}{ATE} \quad (1)$$

$$p(\text{compliers}) = \frac{\text{formareduzida}}{\text{formareduzida/primeiroestagio}} \quad (2)$$

$$p(\text{compliers}) = \text{primeiroestagio} \quad (3)$$

```
coef(lm(pre_natal_adequado ~ Z_mun, data = t_data))['Z_mun']
```

```
Z_mun
1
```

A proporção de compliers é 1, a decisão da mãe buscar pré-natal adequado é unfluenciada pela oferta municipal.

c.

```
metodos <- c('SDO bruto', 'MQO com controles', 'IV')
coeficientes <- c(
  sdo,
  regressao_simples$coefficients["pre_natal_adequado"][[1]],
  regressao_iv$coefficients["pre_natal_adequado"][[1]]
)
erros <- c(
  sqrt(sd(d1$peso)^2/nrow(d1) + sd(d0$peso)^2/nrow(d0)),
  coef(summary(regressao_simples))[, "Std. Error"]["pre_natal_adequado"][[1]],
  coef(summary(regressao_iv))[, "Std. Error"]["pre_natal_adequado"][[1]]
)
est_f <- c(
  NA,
  NA,
  summary(primeiro_estagio)$fstatistic['value'][[1]]
)

tabela <- data.frame(
  metodo = metodos, coeficiente = coeficientes, erro = erros, F = est_f)
tabela
```

	metodo	coeficiente	erro	F
1	SDO bruto	167.45771	4.772044	NA
2	MQO com controles	169.31262	4.224731	NA
3	IV	14.39757	27.186793	1122.038

O método mais confiável é o IV. Apesar de ter problemas na hipótese de exclusão e não ser relevante do ponto de vista de impacto no resultado, mostrou que o MQO estava muito enviesado.