

Resolução da lista 7

Curso de inferência causal

Camila Brito

Seção I - Questões conceituais e teóricas

1. Hipóteses de identificação do matching: CIA e suporte comum

- a. A hipótese de independência condicional (CIA) diz que $(Y_i(0), Y_i(1) \perp D_i | X_i)$. Ela implica que os resultados potenciais $Y(0), Y(1)$ são independentes do tratamento D se condicionados ao vetor de características observáveis X , ou seja, um indivíduo do grupo de controle que possui o vetor de observáveis X é um bom contrafactual para um indivíduo do grupo de tratamento com o mesmo vetor. Ela é considerada mais forte do que a hipótese de independência plena pois exige que **todas** as características confundidoras sejam observados.
- b. A hipótese de suporte comum diz que $0 < Pr[D_i = 1 | X_i] < 1$. Ela é necessária para estimar o ATT pois, para fazer a subtração dos resultados, é necessário que exista uma sobreposição na distribuição dos grupos de controle e tratamento.
- c. Quando usado isoladamente, o matching apresenta limitações, principalmente a existência de características não observáveis, que tornam o matching enviesado (além de outras limitações metodológicas inerentes ao matching, como: qual a distância máxima entre um indivíduo e seu par de controle será permitido? O que fazer quando o suporte comum acaba sendo muito pequeno? etc). A literatura combina matching com DiD usando-o como técnica para criar grupos controle e tratamento parecidos antes de aplicar o DiD. Dessa forma, ele não é usado para estimar o efeito causal em si, apenas na criação de grupos comparáveis.

2. Propensity score e inverse probability weighting

- a. O escore de propensão, definido como $p(x_i) = Pr(D_i = 1 | X_i)$, diz que podemos parear indivíduos com base na probabilidade de receber o tratamento dado o conjunto de características X . Nesse caso, a CIA se torna $(Y_i(0), Y_i(1) \perp D_i | p(X_i))$. Ele resolve a

maldição da dimensionalidade presente no covariate matching ao substituir o pareamento em todo um conjunto de variáveis ao pareamento por um único escore. Ele é estimado usando modelo probit ou logit, incluindo todas as covariadas que podem afetar tanto a participação no tratamento quanto no resultado.

b.

- definir quais covariáveis incluir no PSM afeta o viés do estimador: se variáveis confundidoras não forem incluídas, ou seja, variáveis que afetam tanto o tratamento quanto o resultado, o estimador ficará viesado. Também pode afetar a variância: incluir covariadas que afetam apenas o resultado podem reduzir a variância.
 - número de vizinhos e uso de reposição: quando usamos mais de um vizinho ou temos reposição, um mesmo indivíduo do grupo de controle pode aparecer várias vezes, afetando a variância do estimador
 - caliper máximo: definir uma distância máxima entre unidade tratada e controle pode gerar pareamentos não próximos o suficiente e gerar um estimador enviesado. No entanto, escolher uma distância muito pequena pode levar ao descarte de muitos indivíduos tratados, diminuindo o tamanho da amostra e elevando a variância.
- c. Com IPW, o estimador é dado por $ATE = \frac{1}{N} \sum \frac{D_i Y_i}{p_i} - \frac{1}{N} \sum \frac{(1-D_i) Y_i}{1-p_i}$. Nessa ponderação, casos raros (tratados com baixa probabilidade de tratamento e controles com alta probabilidade de tratamento) recebem um peso maior, criando populações hipotéticas de mesma distribuição em que as características observáveis não tem mais relação com o tratamento, simulando um RTC.

3. Modelo de efeito fixo em dados em painel

- a. O termo α_i é o termo de erro que representa o efeito não observável do indivíduo i que é fixo no tempo. No modelo de efeitos fixos, esse termo é tratado como explicativo do modelo e pode ser correlacionado aos demais regressores X_{it} . Isso viola a hipótese de independência condicional e torna nosso estimador enviesado.
- b. Na transformação within, a média da regressão ao longo do tempo é calculada para cada indivíduo e depois essa média é subtraída do modelo original. Como a média de um termo constante é o próprio termo, essa subtração elimina o termo de erro α_i , já que ele é fixo no tempo. Após essa transformação, todas as variáveis constantes no tempo são perdidas, tanto as não observáveis quanto as observáveis. Isso pode ser uma limitação caso se queira incluir uma covariada que seja invariante no tempo, como características geográficas que ajudariam a explicar o resultado.
- c. O modelo de efeitos fixos exige a hipóteses de exogeneidade estrita, em que o termo de erro remanescente u_{it} **não** pode ser correlacionado aos demais preditores em todo período de tempo t . Já o modelo de efeitos aleatórios, além da hipótese de exogeneidade

estrita, também exige a hipótese do efeito fixo exógeno, ou seja, de que o termo α_i **não** é correlacionado com as outras variáveis explicativas do modelo.

4. Diferenças em diferenças: Estimador, hipótese e bad controls

a.

- O DiD pode ser definido como uma dupla diferença: subtração de antes e depois para cada grupo seguido da subtração entre grupos, ou $\delta_{did} = [E(Y|tratado, depois) - E(Y|tratado, antes)] - [E(Y|controle, depois) - E(Y|controle, antes)]$
- Ele pode ser estimado usando a regressão linear $Y_{it} = \alpha + \beta_1 AFTER_t + \beta_2 TREAT_i + \delta_{did}(AFTER_t \times TREAT_i) + \epsilon_{it}$

- α : representa o baseline do grupo controle ou $E(Y|controle, antes)$
- β_1 : é a tendência temporal do controle (mudança de nível do grupo controle antes e depois do tratamento)
- β_2 : é a diferença de nível entre tratado e controle antes do tratamento
- δ_{did} : estimador do DiD, que representa o efeito causal do tratamento - ATT

- b. A hipótese de tendências paralelas é dada por $E[Y_{s,2}(0) - Y_{s,1}(0)] = E[Y_{n,2}(0) - Y_{n,1}(0)]$. Ela diz que, **na ausência do tratamento** (contrafactual), as tendências temporais dos dois grupos teriam sido as mesmas. O teste de pré-tendências verifica se os coeficientes dos períodos pré-tratamento são próximos de zero. Ele tem algumas limitações: a não garantia que os grupos teriam seguido de forma paralela sem o tratamento e o baixo poder estatístico com poucos períodos pré-tratamento.
- c. A regressão TWFE não deve ser controlada por variáveis que possam ter sido afetadas pelo próprio tratamento pois elas representam *bad controls*: ao adicionar um bad control, ele absorve parte do efeito causal do tratamento e o estimador fica viesado.