

Resolução da lista 8

Curso de inferência causal

Camila Brito

```
# Instalação de pacotes e bases
# install.packages(c("haven", "dplyr", "ggplot2", "fixest",
# "plm", "MatchIt", "cobalt", "lmtest",
# "sandwich", "modelsummary"))

library(haven); library(dplyr); library(ggplot2)
library(fixest) # pacote principal desta lista
library(plm)    # apenas para RE e Hausman
library(MatchIt); library(cobalt)
library(lmtest); library(sandwich)
library(glue)

# Carregue as bases
painel <- read_dta('dados/base_painel.dta')
hisp   <- read_dta('dados/Dados_HISP_MicroIV.dta')
```

Parte I - Dados em Painel: modelo econômico do crime

1. Exploração dos dados e variação within/between

a.

```
n <- glue("Tamanho da tabela: {nrow(painel)}")
cols <- glue("Colunas da tabela: {paste0(unlist(names(painel)), collapse=', ')}")
print(n)
```

Tamanho da tabela: 630

```
print(cols)
```

Colunas da tabela: county, year, crmrte, prbarr, prbconv, prbpris, avgsen, polpc, density, w

prbarr é a probabilidade de prisão (a variável independente) e crmrte é a taxa de criminalidade (a variável resposta).

```
painel %>%
  summarise(N = n_distinct(county),
            T = n_distinct(year),
            obs = n())
```

```
# A tibble: 1 x 3
      N     T  obs
  <int> <int> <int>
1    90     7  630
```

O painel tem 90 indivíduos distintos ao longo de 7 anos, gerando 630 observações.

- b. As variações **between** são as variações entre condados (indivíduos/unidades) e as **within** são as variações ao longo do tempo dentro de um mesmo condado.

```
painel %>%
  group_by(county) %>%
  mutate(crmrte_bar = mean(crmrte),
         prbarr_bar = mean(prbarr)) %>%
  ungroup() %>%
  summarise(
    sd_total_crime = sd(crmrte),
    sd_between_crime = sd(crmrte_bar),
    sd_within_crime = sd(crmrte - crmrte_bar),
    sd_total_arr = sd(prbarr),
    sd_between_arr = sd(prbarr_bar),
    sd_within_arr = sd(prbarr - prbarr_bar)
  )
```

```
# A tibble: 1 x 6
  sd_total_crime sd_between_crime sd_within_crime sd_total_arr sd_between_arr
          <dbl>          <dbl>          <dbl>          <dbl>          <dbl>
1      0.0181      0.0169      0.00652      0.171      0.135
# i 1 more variable: sd_within_arr <dbl>
```


A variável de probabilidade de prisão apresenta a maior variação within. Se a variação de uma variável for muito pequena, pode ser que não seja possível capturar nenhum efeito causal. Além disso, se a variação temporal de uma variável for nula, o modelo de efeitos fixos some com ela e não é possível estimar seu efeito.

c.


```
# Variáveis em log e demeaned
paine1 <- paine1 %>%
  mutate(
    lcrmte = log(crmte), lprbarr = log(prbarr),
    lprbconv = log(prbconv), lpolpc = log(polpc),
    lpctymle = log(pctymle)
  ) %>%
  group_by(county) %>%
  mutate(
    dm_lcrmte = lcrmte - mean(lcrmte),
    dm_lprbarr = lprbarr - mean(lprbarr)
  ) %>%
  ungroup()

sel <- paine1 %>% filter(county %in% c(1, 3, 23, 145))

# Bruto
ggplot(sel, aes(lprbarr, lcrmte, color=factor(county))) +
  geom_point() +
  geom_smooth(method="lm", se=FALSE) +
  labs(title="Bruto", x="log P(Arrest)", y="log Crime Rate")
```



```
# Demeaned (within)
ggplot(sel, aes(dm_lprbarr, dm_lcrmrate, color=factor(county))) +
  geom_point() +
  geom_smooth(method="lm", se=FALSE) +
  labs(title="Demeaned (within)", x="dm P(Arrest)", y="dm Crime Rate")
```



No gráfico com os dados brutos, cada condado tem um nível diferente de prisão e taxa de crime. Já no gráfico demeaned, todos se concentram em torno do zero. Isso mostra que as características inerentes de cada condado foram removidas e podemos olhar para o efeito da prisão sobre a taxa de crime.

2. POLS, efeito fixo e TWFE com fixest

- a. Regressão usando como controle a probabilidade de condenação (`lprbconv`), a porcentagem de polícia per capta (`lpolpc`) e a porcentagem de homens jovens (`lpctymle`).

```
pols <- feols(lcrmte ~ lprbarr + lprbconv + lpolpc + lpctymle,
  data = painel)
summary(pols)
```

OLS estimation, Dep. Var.: `lcrmte`

Observations: 630

Standard-errors: IID

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-2.491370	0.274928	-9.061913	< 2.2e-16 ***
<code>lprbarr</code>	-0.718448	0.038644	-18.591638	< 2.2e-16 ***
<code>lprbconv</code>	-0.558822	0.027111	-20.612632	< 2.2e-16 ***
<code>lpolpc</code>	0.357628	0.030541	11.709635	< 2.2e-16 ***

```
lpctymle      0.040659    0.083082    0.489382    0.62474
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
RMSE: 0.381335    Adj. R2: 0.553259
```

O estimador é provavelmente viesado pois não controla por confundidores não observáveis.

- b. Efeito fixo de condado para absorver as características não observáveis fixas no tempo para cada condado.

```
fe <- feols(lcrmrte ~ lprbarr + lprbconv + lpolpc + lpctymle |
county,
  data = painel, cluster = ~county)
summary(fe)
```

```
OLS estimation, Dep. Var.: lcrmrte
```

```
Observations: 630
```

```
Fixed-effects: county: 90
```

```
Standard-errors: Clustered (county)
```

	Estimate	Std. Error	t value	Pr(> t)	
lprbarr	-0.342735	0.055270	-6.20113	1.7196e-08	***
lprbconv	-0.277182	0.050107	-5.53183	3.1457e-07	***
lpolpc	0.399146	0.082959	4.81136	6.0789e-06	***
lpctymle	0.455207	0.194825	2.33649	2.1711e-02	*

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
RMSE: 0.138653    Adj. R2: 0.931132
```

```
Within R2: 0.326786
```

```
# Efeitos fixos estimados (interceptos por condado)
```

```
fixef(fe)[["county"]][1:6]
```

	1	3	5	7	9	11
	-0.2652546	-0.7737207	-1.0314597	-0.4821138	-0.9070773	-1.2714655

Na regressão com efeitos fixos de condado, um aumento de 10% na probabilidade de prisão passa a estar associado a uma diminuição de $\log(34.2) = 1.5\%$ na taxa de crime. Em relação à regressão simples, o efeito da probabilidade de prisão sobre a taxa de criminalidade diminui, pois os efeitos fixos estão absorvendo parte do efeito que a regressão simples não conseguiu capturar. É equivalente a fazer uma variável dummy para cada condado e controlar por eles.

- c. TWFE é quando adicionamos efeito fixo de tempo, para absorver características não observáveis variantes no tempo comuns a todos os condados (como choques).

```
twfe <- feols(lcrmte ~ lprbarr + lprbconv + lpolpc + lpctymle
| county + year,
data = painel, cluster = ~county)
summary(twfe)
```

```
OLS estimation, Dep. Var.: lcrmte
Observations: 630
Fixed-effects: county: 90, year: 7
Standard-errors: Clustered (county)

      Estimate Std. Error   t value   Pr(>|t|)
lprbarr  -0.307315   0.057572  -5.337936  7.1132e-07 ***
lprbconv  -0.251705   0.051560  -4.881775  4.5921e-06 ***
lpolpc    0.400191   0.087631   4.566799  1.5836e-05 ***
lpctymle  0.361457   0.551808   0.655041  5.1413e-01
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.130771      Adj. R2: 0.938046
                Within R2: 0.331799
```

```
# Tabela comparativa com etable()
etable(pols, fe, twfe,
coefstat = "se",
dict = c(lprbarr="log P(Arrest)", lprbconv="log P(Conv)",
lpolpc="log Polícia p.c."))
```

	pols	fe	twfe
Dependent Var.:	lcrmte	lcrmte	lcrmte
Constant	-2.491*** (0.2749)		
log P(Arrest)	-0.7184*** (0.0386)	-0.3427*** (0.0553)	-0.3073*** (0.0576)
log P(Conv)	-0.5588*** (0.0271)	-0.2772*** (0.0501)	-0.2517*** (0.0516)
log Polícia p.c.	0.3576*** (0.0305)	0.3991*** (0.0830)	0.4002*** (0.0876)
lpctymle	0.0407 (0.0831)	0.4552* (0.1948)	0.3615 (0.5518)
Fixed-Effects:	-----	-----	-----
county	No	Yes	Yes
year	No	No	Yes
S.E. type	-----	-----	-----
	IID	by: county	by: county

Observations	630	630	630
R2	0.55610	0.94131	0.94780
Within R2	--	0.32679	0.33180

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Adicionando efeitos fixos de tempo (FE), o coeficiente diminuiu um pouco mais, mostrando que alguma característica temporal comum a todos os condados pode ter ajudado a diminuir a taxa de criminalidade.

Observação: usar `county + year != county^year` `county^year` representa a interação entre condado e ano. No nosso caso, não é possível fazer essa interação, pois ano já é a unidade mais granular de tempo e não teríamos variação nenhuma. Mas caso possuíssimos observações mensais, poderíamos usar essa interação, como se comparássemos apenas observações dentro de um mesmo condado e dentro de um mesmo ano.

3. Efeito Aleatório, Hausman e Tabela Final

a.

```
painel_pd <- pdata.frame(painel, index = c("county", "year"))
fe_plm <- plm(lcrmrte ~ lprbarr + lprbconv + lpolpc + lpctymle,
  data = painel_pd, model = "within")
re <- plm(lcrmrte ~ lprbarr + lprbconv + lpolpc + lpctymle,
  data = painel_pd, model = "random")
summary(re)
```

Oneway (individual) effect Random Effect Model
(Swamy-Arora's transformation)

Call:

```
plm(formula = lcrmrte ~ lprbarr + lprbconv + lpolpc + lpctymle,
  data = painel_pd, model = "random")
```

Balanced Panel: n = 90, T = 7, N = 630

Effects:

	var	std.dev	share
idiosyncratic	0.0226	0.1503	0.164
individual	0.1155	0.3399	0.836
theta:	0.8351		

Residuals:

Min.	1st Qu.	Median	3rd Qu.	Max.
-0.978232	-0.080488	0.010859	0.089798	0.569774

Coefficients:

	Estimate	Std. Error	z-value	Pr(> z)
(Intercept)	-0.687138	0.347576	-1.9769	0.0480480 *
lprbarr	-0.394881	0.031903	-12.3776	< 2.2e-16 ***
lprbconv	-0.309892	0.020980	-14.7709	< 2.2e-16 ***
lpolpc	0.402368	0.027009	14.8978	< 2.2e-16 ***
lpctymle	0.420944	0.123677	3.4036	0.0006651 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares: 23.111

Residual Sum of Squares: 14.976

R-Squared: 0.352

Adj. R-Squared: 0.34786

Chisq: 339.511 on 4 DF, p-value: < 2.22e-16

No modelo de efeitos aleatórios (RE), o coeficiente é um pouco maior. Uma grande divergência entre os coeficientes nos dois modelos pode indicar que há correlação entre $_i$ e os estimadores X_it . Sob sua hipótese de identificação, RE é mais eficiente que FE pois tem uma variância menor dos estimadores, gerando erros padrão menores. Além disso, permite usar variáveis fixas no tempo que diferem entre indivíduos, aproveitando mais informações dos dados e ganhando precisão.

b.

```
phtest(fe_plm, re)
```

Hausman Test

```
data: lcrmrte ~ lprbarr + lprbconv + lpolpc + lpctymle
chisq = 96.981, df = 4, p-value < 2.2e-16
alternative hypothesis: one model is inconsistent
```

O p-valor é « 0.05, então rejeitamos a hipótese nula de que RE é consistente -> $Cov(_i, X_it) \neq 0$. Isso significa que RE é viesado e devemos usar FE.

c.

```
# POLS, FE e TWFE via fixest
etable(pols, fe, twfe,
  coefstat = "se", signif.code =
c("***"=.01,"**"=.05,"*"=.1),
  keep = "lprbarr",
  headers = list("_Modelo_" =
list("POLS"=1,"FE"=1,"TWFE"=1)))
```

	pols	fe	twfe
Dependent Var.:	lcrmrte	lcrmrte	lcrmrte
Modelo_	POLS	FE	TWFE
lprbarr	-0.7184*** (0.0386)	-0.3427*** (0.0553)	-0.3073*** (0.0576)
Fixed-Effects:	-----	-----	-----
county	No	Yes	Yes
year	No	No	Yes
-----	-----	-----	-----
S.E. type	IID	by: county	by: county
Observations	630	630	630
R2	0.55610	0.94131	0.94780
Within R2	--	0.32679	0.33180

Signif. codes:	0 '***' 0.01 '**' 0.05 '*' 0.1 ' ' 1		

```
# RE via modelsummary (aceita objetos plm)
library(modelsummary)
modelsummary(list(RE = re),
  coef_map = c(lprbarr = "log P(Arrest)"),
  stars = TRUE)
```

Parte II — Seleção em Observáveis: PSM e DiD com o HISP

4. Análise Exploratória e Viés de Seleção

a.

	RE
log P(Arrest)	−0.395*** (0.032)
Num.Obs.	630
R2	0.352
R2 Adj.	0.348
AIC	−555.9
BIC	−529.2
RMSE	0.15

+ p <0.1, * p <0.05, ** p <0.01, *** p <0.001

```
baseline <- hisp %>% filter(round == 0)
baseline %>%
  group_by(enrolled) %>%
  summarise(across(
    c(health_expenditures, age_hh, educ_hh, poverty_index, hhsize),
    mean, na.rm=TRUE))
```

```
# A tibble: 2 x 6
  enrolled health_expenditures age_hh educ_hh poverty_index hhsize
  <dbl>          <dbl> <dbl>   <dbl>          <dbl> <dbl>
1       0          18.4  48.1    2.77          60.0  4.93
2       1          14.5  41.7    2.97          49.3  5.77
```

As covariáveis de gasto com saúde, idade e índice de pobreza apresentam grande variação entre os grupos.

b.

```
followup <- hisp %>% filter(round == 1)
followup %>%
  group_by(enrolled) %>%
  summarise(media_gasto = mean(health_expenditures, na.rm=TRUE)) %>%
  summarise(dif = diff(media_gasto))
```

```
# A tibble: 1 x 1
```

```
    dif
    <dbl>
1 -12.9
```

A diferença simples das médias de gastos entre inscritos e não inscritos no follow up não pode ser interpretada casualmente, pois pode haver diversas variáveis confundidoras enviesando o resultado. Uma família mais jovem pode naturalmente gastar menos com saúde estando ou não inscrita no programa.

c.

```
ols_naive <- lm(health_expenditures ~ enrolled + age_hh + educ_hh +
               poverty_index + hhsiz e + female_hh + indigenous,
               data = followup)
coeftest(ols_naive, vcov = vcovHC(ols_naive, type = "HC1"))
```

t test of coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	21.6378020	0.7356684	29.4124	< 2.2e-16 ***
enrolled	-9.5247867	0.1880870	-50.6403	< 2.2e-16 ***
age_hh	0.0570217	0.0078154	7.2960	3.191e-13 ***
educ_hh	0.0166323	0.0382246	0.4351	0.66349
poverty_index	0.1016348	0.0112788	9.0111	< 2.2e-16 ***
hhsiz e	-1.8552299	0.0480392	-38.6191	< 2.2e-16 ***
female_hh	1.0713464	0.4170481	2.5689	0.01022 *
indigenous	-2.6539581	0.1858017	-14.2838	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

O coeficiente diminui em relação à diferença simples. A inclusão de controles melhora mas não resolve o problema de viés de seleção.

5. Propensity Score Matching

- a. Calculando a chance de ser tratado baseado em várias características e rodando um logit. A ideia é encontrar indivíduos parecidos na probabilidade de ser tratado, mas que um foi tratado e outro não e, assim, encontrar grupos comparáveis.

```
m_out <- matchit(
  enrolled ~ age_hh + age_sp + educ_hh + educ_sp +
  female_hh + indigenous + hhsize +
  dirtfloor + bathroom + land,
  data = followup,
  method = "nearest",
  distance = "logit",
  ratio = 1,
  replace = FALSE
)
summary(m_out)
```

Call:

```
matchit(formula = enrolled ~ age_hh + age_sp + educ_hh + educ_sp +
  female_hh + indigenous + hhsize + dirtfloor + bathroom +
  land, data = followup, method = "nearest", distance = "logit",
  replace = FALSE, ratio = 1)
```

Summary of Balance for All Data:

	Means Treated	Means Control	Std. Mean Diff.	Var. Ratio	eCDF Mean
distance	0.3683	0.2695	0.7570	0.8500	0.1983
age_hh	42.6270	49.1025	-0.4728	0.7785	0.0892
age_sp	37.6384	42.4051	-0.4091	0.7960	0.0638
educ_hh	2.9712	2.7752	0.0740	0.8954	0.0218
educ_sp	2.7067	2.5825	0.0502	0.9258	0.0142
female_hh	0.0732	0.1101	-0.1417	.	0.0369
indigenous	0.4293	0.3203	0.2202	.	0.1090
hhsize	5.7703	4.9263	0.4228	0.8028	0.0652
dirtfloor	0.7214	0.5533	0.3750	.	0.1681
bathroom	0.5737	0.6340	-0.1220	.	0.0604
land	1.6789	2.2511	-0.2164	0.6397	0.0240

	eCDF Max
distance	0.3086
age_hh	0.2089
age_sp	0.2059
educ_hh	0.0623
educ_sp	0.0696
female_hh	0.0369
indigenous	0.1090
hhsize	0.1834
dirtfloor	0.1681

bathroom	0.0604
land	0.0880

Summary of Balance for Matched Data:

	Means Treated	Means Control	Std. Mean Diff.	Var. Ratio	eCDF Mean
distance	0.3683	0.3676	0.0056	1.0137	0.0009
age_hh	42.6270	42.5960	0.0023	1.1098	0.0123
age_sp	37.6384	37.7234	-0.0073	1.1652	0.0114
educ_hh	2.9712	2.9905	-0.0073	0.9512	0.0063
educ_sp	2.7067	2.6820	0.0100	0.9572	0.0057
female_hh	0.0732	0.0776	-0.0168	.	0.0044
indigenous	0.4293	0.4280	0.0027	.	0.0013
hhsiz	5.7703	5.7551	0.0076	0.8660	0.0112
dirtfloor	0.7214	0.7228	-0.0030	.	0.0013
bathroom	0.5737	0.5734	0.0007	.	0.0003
land	1.6789	1.6712	0.0029	1.0707	0.0037

	eCDF Max	Std. Pair Dist.
distance	0.0115	0.0058
age_hh	0.0320	0.9020
age_sp	0.0368	0.9368
educ_hh	0.0152	1.0776
educ_sp	0.0202	1.0936
female_hh	0.0044	0.5115
indigenous	0.0013	0.8885
hhsiz	0.0266	1.0177
dirtfloor	0.0013	0.6651
bathroom	0.0003	0.9814
land	0.0209	0.8285

Sample Sizes:


	Control	Treated
All	6949	2965
Matched	2965	2965
Unmatched	3984	0
Discarded	0	0

No matched data, parte dos controles foi descartada, mantendo apenas os mais parecidos com os tratados. As médias dos dois grupos para as variáveis observáveis são bastante semelhantes.


b.

```
plot(m_out, type = "jitter", interactive = FALSE)
```

Distribution of Propensity Scores



```
# Alternatively: love plot (cobalt)  
love.plot(m_out, threshold = 0.1)
```



O suporte comum parece razoável, cobrindo toda a extensão do grupo de tratados. Foram excluídos 3984 indivíduos do grupo de controle.

c.

```
matched_data <- match.data(m_out)
att_psm <- lm(health_expenditures ~ enrolled,
  data = matched_data,
  weights = weights)
coeftest(att_psm, vcov = vcovCL(att_psm, cluster = ~subclass))
```

t test of coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	17.68153	0.15034	117.614	< 2.2e-16 ***
enrolled	-9.84135	0.19714	-49.921	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

O coeficiente passa a ser de -9.8. O programa praticamente atingiu seu objetivo de redução com gastos em saúde.

6. Diferenças em Diferenças

a.

```
hisp <- hisp %>%  
  mutate(  
    after = as.integer(round == 1),  
    treat = enrolled  
  )  
# Checar N por grupo e período  
hisp %>% count(treat, after)
```

```
# A tibble: 4 x 3  
  treat after     n  
  <dbl> <int> <int>  
1     0     0 6949  
2     0     1 6949  
3     1     0 2964  
4     1     1 2965
```

b.

```
# (i) DiD 2x2 com controles - feols com SE clusterizados  
did_2x2 <- feols(  
  health_expenditures ~ treat * after + age_hh + educ_hh +  
  poverty_index,  
  data = hisp, cluster = ~locality_identifier  
)  
# (ii) TWFE: FE de domicílio + FE de período  
# A variação explorada é: mudança dentro do domicílio ao longo do tempo  
did_twfe <- feols(  
  health_expenditures ~ i(after, treat, ref = 0) |  
  household_identifier + round,  
  data = hisp, cluster = ~locality_identifier  
)  
etable(did_2x2, did_twfe)
```

	did_2x2	did_twfe
Dependent Var.:	health_expenditures	health_expenditures
Constant	0.5369 (0.6695)	

```

treat          -0.9120*** (0.2453)
after           2.259*** (0.2250)
age_hh          0.0798*** (0.0070)
educ_hh         0.0439 (0.0332)
poverty_index   0.2313*** (0.0097)
treat x after   -8.985*** (0.2829)
treat x after = 1          -8.986*** (0.2828)
Fixed-Effects:  -----
household_identifier      No          Yes
round                     No          Yes
-----
S.E.: Clustered      by: locality_iden.. by: locality_iden..
Observations          19,827          19,826
R2                    0.30647          0.75870
Within R2             --             0.16881
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

O coeficiente de treat x after com e sem controles é praticamente igual, mostrando que os controles são suficientes e os efeitos fixos não absorvem muita variação. Isso pode acontecer pelo fato de só haver dois períodos no tempo.

c.

```

trend_data <- hisp %>%
  group_by(round, treat) %>%
  summarise(media = mean(health_expenditures, na.rm=TRUE))
ggplot(trend_data, aes(x=round, y=media,
  color=factor(treat), group=factor(treat))) +
  geom_line(linewidth=1.2) + geom_point(size=3) +
  scale_x_continuous(breaks=c(0,1),
  labels=c("Baseline","Follow-up")) +
  scale_color_manual(values=c("0"="#2E5395","1"="#C0392B"),
  labels=c("Controle","Tratado")) +
  labs(title="Tendências: Despesas com Saúde",
  y="Despesa média (US$)", x="", color="Grupo")

```

